

UNIVERSIDADE DO VALE DO RIO DOS SINOS
UNIDADE ACADÊMICA DE GRADUAÇÃO
CURSO DE BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

GABRIELA BLEY RODRIGUES

MINAS: MULTI-AGENT INTENT-DRIVEN NETWORK ANALYTICS AND SLICING

SÃO LEOPOLDO
2026

Gabriela Bley Rodrigues

MINAS: MULTI-AGENT INTENT-DRIVEN NETWORK ANALYTICS AND SLICING

Monografia apresentada como requisito parcial
para obtenção do título de Bacharel em Ciência
da Computação, pelo Curso de Ciência da Com-
putação da Universidade do Vale do Rio dos Si-
nos (UNISINOS)

Orientador:
Prof. Dr. Cristiano Bonato Both

São Leopoldo
2026

Aos nossos pais.

*If I have seen farther than others,
it is because I stood on the shoulders of giants.*
— SIR ISAAC NEWTON

AGRADECIMENTOS

Obrigada!

RESUMO

Este trabalho aborda o problema do gerenciamento autônomo de fatias de rede na quinta geração de redes móveis (*Fifth Generation* (5G)), com foco no uso de *Large Language Models* (LLMs) e *Multi-Agent Systems* (MAS) para esse fim. As redes 5G, estruturadas sobre uma *Service-Based Architecture* (SBA) e equipadas com funções analíticas como a *Network Data Analytics Function* (NWDAF), demandam mecanismos de orquestração capazes de interpretar objetivos do operador e traduzi-los em configurações executáveis de forma autônoma. Este trabalho propõe o *Multi-agent Intent-driven Network Analytics and Slicing* (MINAS), uma arquitetura hierárquica composta por um agente orquestrador, que interpreta intenções expressas em linguagem natural, e dois agentes especializados: o *CN-Network Slice Subnet Management Function* (NSSMF), responsável pelas funções do núcleo da rede (*5G Core* (5GC)), e o *RAN-NSSMF*, responsável pelos recursos de acesso rádio. Os agentes são implantados como contêineres Docker integrados à NWDAF por meio de suas interfaces normativas, e toda a coordenação é mediada pelo agente orquestrador por meio da *Model Context Protocol* (MCP). O sistema é validado em um ambiente experimental em nuvem composto pelo Open5GS e pelo UERANSIM, com integração à NWDAF como fonte de telemetria e suporte analítico. O trabalho apresenta uma proposta de arquitetura de orquestração baseada em intenções (*Intent-Based Networking* (IBN)), evidenciando o papel dos LLMs como tradutores semânticos em ambientes de missão crítica.

Palavras-chave: *Redes 5G. Sistemas Multiagentes. Open RAN. NWDAF. Redes Baseadas em Intenção. Grandes Modelos de Linguagem.*

ABSTRACT

This work addresses the problem of autonomous network slice management in fifth-generation mobile networks (5G), focusing on the use of LLMs and MAS for this purpose. 5G networks, built upon a SBA and equipped with analytical functions such as the NWDAF, demand orchestration mechanisms capable of interpreting operator objectives and autonomously translating them into executable configurations. This work proposes MINAS, a hierarchical architecture composed of an orchestrator agent, which interprets intents expressed in natural language, and two specialized agents: the CN-NSSMF, responsible for core network functions (5GC), and the RAN-NSSMF, responsible for radio access resources. The agents are deployed as Docker containers integrated with the NWDAF through its normative interfaces, and all coordination is mediated by the orchestrator agent via MCP. The system is validated in a cloud-based experimental environment comprising Open5GS and UERANSIM, with integration to the NWDAF as a telemetry source and analytical support. This work provides an architectural proposal for Intent-Based Networking (IBN) orchestration, highlighting the role of LLMs as semantic translators in mission-critical environments.

Keywords: 5G Networks. Multi-Agent Systems. Open RAN. NWDAF. Intent-Based Networks. Large Language Models.

LISTA DE FIGURAS

Figura 1:	Fluxo de coleta, processamento e exposição analítica na arquitetura 5GC e NWDAF.	14
Figura 2:	Arquitetura Open RAN destacando a desagregação da estação rádio base e os níveis de controle do RIC.	15
Figura 3:	Arquitetura da integração de IA no ecossistema O-RAN utilizando Non-RT RIC e Near-RT RIC.	17
Figura 4:	Representação do Agentic Serving e sistemas multiagentes no 5GC.	19
Figura 5:	Desagregação de inferência de LLM, migração de KV Cache e isolamento via Wasm no contínuo Core-Edge.	21
Figura 6:	Arquitetura em camadas do MINAS.	37
Figura 7:	Diagrama de sequência do Caso de Uso 1 — predição e ajuste autônomo de recursos de fatia.	40
Figura 8:	Diagrama de sequência do Caso de Uso 2 — política de <i>Quality of Service</i> (QoS) agendada com coordenação núcleo- <i>Radio Access Network</i> (RAN). . .	41

LISTA DE TABELAS

Tabela 1:	Lista dos artigos selecionados.	24
Tabela 2:	Características dos trabalhos relacionados.	34
Tabela 3:	Cronograma das próximas etapas do trabalho.	43

SUMÁRIO

1	INTRODUÇÃO	9
2	FUNDAMENTAÇÃO TEÓRICA	11
2.1	Arquitetura do core do 5G	11
2.2	Rede de Acesso de Rádio e Open RAN	14
2.3	Agentes Inteligentes e Redes Baseadas em Intenção	16
2.4	Grandes Modelos de Linguagem	20
3	TRABALHOS RELACIONADOS	23
3.1	<i>Intent Based Networking</i> e análises NWDAF	23
3.2	Orquestração dinâmica e <i>Network Slicing</i>	26
3.3	Inteligência de borda (<i>Edge O-RAN</i> e <i>Multi Agent System</i>)	28
3.4	Diagnóstico de falhas e <i>Self-Organizing Networks</i>	30
3.5	Protocolos semânticos, revisões sistemáticas e <i>Surveys</i>	31
3.6	Discussão e lacunas identificadas	32
4	MINAS - <i>MULTI-AGENT INTENT-DRIVEN NETWORK ANALYTICS AND SLICING</i>	35
4.1	Arquitetura do sistema proposto	35
4.2	Decisões de projeto	36
4.3	Casos de uso e avaliação de desempenho	39
5	CONSIDERAÇÕES FINAIS	42
	REFERÊNCIAS	44

1 INTRODUÇÃO

A evolução das redes móveis em direção à quinta geração avançada representa uma transformação profunda na forma como a infraestrutura de telecomunicações é concebida e operada. Diferentemente das gerações anteriores, o 5G foi projetado para ser nativamente compatível com ambientes virtualizados e orientados à nuvem, introduzindo conceitos como fatiamento de rede (*network slicing*), arquitetura baseada em serviços (SBA) e funções de rede analíticas como a NWDAF (3GPP, 2024c; MAYER et al., 2018). Essa base tecnológica viabiliza um novo paradigma de gerenciamento, no qual a inteligência deixa de ser um componente isolado e passa a fazer parte da própria estrutura da rede. Nesse contexto, o paradigma de IBN surge como uma abordagem essencial para substituir configurações manuais por diretrizes expressas em linguagem natural, permitindo que o sistema interprete os objetivos do operador e os execute de forma autônoma (3GPP, 2023b; TM Forum, 2022).

Para viabilizar essa autonomia, os LLMs têm emergido como motores de raciocínio capazes de atuar como tradutores semânticos entre o operador humano e a infraestrutura de rede (BARIHAH et al., 2024b; ZHOU et al., 2024). Ao contrário das abordagens tradicionais baseadas em regras, os LLMs conseguem decompor objetivos abstratos em sequências de ações executáveis, como chamadas de *Application Programming Interface* (API), e coordenar múltiplos agentes especializados em um sistema multiagente (MAS) (WOOLDRIDGE, 2009). Essa capacidade é especialmente relevante no contexto do 5GC e da arquitetura *Open RAN* (O-RAN), em que decisões de configuração envolvem simultaneamente domínios heterogêneos, como o núcleo da rede e a camada de acesso rádio, com requisitos distintos de latência e isolamento.

Reconhecendo esse cenário, o presente trabalho propõe uma arquitetura de orquestração autônoma de fatias de rede 5G baseada em MAS e LLMs. A solução é estruturada em torno de um agente orquestrador que interpreta intenções do operador expressas em linguagem natural e as decompõe em diretivas para dois agentes especializados: o CN-NSSMF, responsável pelas funções do núcleo da rede, e o RAN-NSSMF, responsável pelos recursos de acesso por rádio. A coordenação entre os agentes é realizada por meio do MCP, e o sistema é validado em um *testbed* real composto pelo Open5GS e pelo UERANSIM, integrando nativamente a NWDAF como fonte de telemetria e de suporte analítico.

A partir dessa perspectiva, este trabalho busca contribuir para a literatura acadêmica sobre automação cognitiva de redes móveis, posicionando-se no contexto mais amplo da convergência entre Inteligência Artificial (IA) generativa e infraestrutura de telecomunicações. A proposta tem potencial para abrir novos caminhos para pesquisas que buscam conciliar os avanços recentes em LLMs com as restrições operacionais típicas de ambientes de missão crítica. Para isso, esta monografia está organizada da seguinte forma: o Capítulo 2 apresenta a fundamentação teórica, abordando a arquitetura do 5GC, a O-RAN, os agentes inteligentes e os LLMs. O Capítulo 3 apresenta uma revisão sistemática dos trabalhos relacionados. O Capítulo 4 descreve a proposta arquitetural e os casos de uso. Por fim, o Capítulo 5 apresenta as considerações finais

e as próximas etapas do trabalho.

2 FUNDAMENTAÇÃO TEÓRICA

O presente capítulo apresenta os principais fundamentos teóricos e tecnológicos que embasam o desenvolvimento desta pesquisa. A organização do texto segue uma linha dedutiva, iniciando com uma visão mais ampla sobre a transição das arquiteturas de redes celulares em direção à computação em nuvem e, em seguida, aprofundando a discussão nos componentes analíticos e nos mecanismos de suporte à decisão. Na sequência, são abordados os conceitos centrais da IBN e a modelagem de funções de rede por meio de agentes inteligentes. Por fim, o capítulo explora a arquitetura dos LLM e os princípios de infraestrutura necessários para o seu *serving* e execução em ambientes de missão crítica, estabelecendo uma conexão entre as demandas das redes modernas e os avanços recentes em IA.

2.1 Arquitetura do core do 5G

A transição tecnológica da *Fourth Generation* (4G) para a 5G vai além de um simples aumento nas taxas de transmissão; representa uma reestruturação significativa da infraestrutura de rede necessária para acompanhar a evolução digital da sociedade. O padrão 4G é baseado na tecnologia *Long-term Evolution* (LTE) e em um núcleo de rede mais rígido, estruturado sobre o protocolo IP, conhecido como *Evolved Packet Core* (EPC) (ČAUŠEVIĆ; MEDIĆ, 2021). Já a arquitetura 5G é concebida para ser nativamente compatível com ambientes virtualizados e orientados à nuvem, integrando e ampliando as capacidades das gerações anteriores (ČAUŠEVIĆ; MEDIĆ, 2021; 3GPP, 2024c). Do ponto de vista da infraestrutura, essa nova geração introduz o conceito de redes heterogêneas ultradensas, formadas por um grande número de macrocélulas e pequenas células (*small cells*), com o objetivo de ampliar a cobertura e a capacidade da rede, o que, em contrapartida, exige técnicas avançadas de gerenciamento de interferência intercelular.

Essa topologia é viabilizada por um conjunto de tecnologias capacitadoras, como *Software-Defined Networking* (SDN), *Network Function Virtualization* (NFV) e *Multi-access Edge Computing* (MEC). Nesse contexto, o MEC desempenha um papel central na garantia de desempenho para aplicações de missão crítica, ao descentralizar o processamento e aproximar os recursos computacionais da borda da rede, tipicamente posicionados junto às estações rádio-base (*gNodeB*) ou em agregadores regionais próximos ao *User Equipment* (UE). Essa base virtualizada também viabiliza o conceito de fatiamento de rede (*network slicing*), permitindo que a mesma infraestrutura física seja segmentada em múltiplas redes lógicas, isoladas de ponta a ponta. Dessa forma, é possível assegurar que diferentes tipos de tráfego atendem aos seus respectivos *Service Level Agreement* (SLA) (MAYER et al., 2018).

Gerenciamento hierárquico de fatias de rede

O gerenciamento do ciclo de vida de uma fatia de rede é estruturado pelo *3rd Generation Partnership Project* (3GPP) em uma hierarquia de três funções, definidas na especificação TS 28.533 (3GPP, 2024b). No topo, a *Communication Service Management Function* (CSMF) recebe as solicitações do operador e as traduz em requisitos de rede. A *Network Slice Management Function* (NSMF) coordena o ciclo de vida da fatia de ponta a ponta, garantindo que os recursos alocados nos diferentes domínios satisfaçam os SLA contratados. Por fim, a *NSSMF* opera no nível das sub-redes que compõem cada fatia, gerenciando domínios específicos de forma independente. Na prática, essa especialização resulta em duas instâncias principais: o **CN-NSSMF**, responsável pela gestão das funções do núcleo (5GC), como *Session Management Function* (SMF), *Access and Mobility Management Function* (AMF) e *User Plane Function* (UPF); e o **RAN-NSSMF**, responsável pela configuração dos recursos de acesso rádio, incluindo os parâmetros das unidades *Distributed Unit* (DU) e *Centralized Unit* (CU) na arquitetura O-RAN. Essa decomposição é fundamental para que sistemas de orquestração autônoma possam atuar de forma coordenada sobre domínios heterogêneos, respeitando as interfaces normativas do 3GPP e os requisitos de isolamento de cada fatia.

A principal mudança arquitetural da 5G está no desenho do seu núcleo de rede (5GC), que abandona abordagens monolíticas em favor da SBA (MAYER et al., 2018; 3GPP, 2024c). Nessa abordagem, as entidades da rede passam a ser tratadas como *Network Function* (NF) independentes, que se comunicam de forma flexível por meio de API, geralmente baseadas na arquitetura *RESTful*.

A SBA representa o núcleo da modernização do 5G, pois substitui o *hardware* dedicado por NF modularizadas e desenvolvidas de forma nativa para a nuvem (*cloud-native*). Nesse modelo, a comunicação no plano de controle passa a ocorrer por meio de um barramento lógico de serviços, utilizando API padronizadas sobre HTTP/2 com codificação JSON e contratos descritos em OpenAPI, conforme estabelecido na 3GPP TS 29.500 (MAYER et al., 2018; 3GPP, 2024a). Com essa mudança, a IA deixa de ser um componente isolado e passa a fazer parte da própria estrutura do 5GC, viabilizando mecanismos de auto-otimização em tempo real. Nesse contexto, a NWDAF foi padronizada pelo 3GPP para atuar como o principal elemento de suporte à inteligência na rede. Introduzida no Release 15 com escopo restrito, voltado essencialmente ao fornecimento de informações de carga para fatias de rede, a NWDAF foi substancialmente expandida no Release 16 (TS 23.288), passando a contemplar casos de uso como previsão de mobilidade, análise de comportamento de UE e desempenho de NF. Os Releases 17 e 18 ampliaram ainda mais essas capacidades, incorporando aprendizado federado entre múltiplas NWDAF e *analytics* relacionados à sustentabilidade e à eficiência energética da QoS (3GPP, 2023a; OLIVEIRA et al., 2024).

O papel da NWDAF está centrado na coleta de grandes volumes de dados de telemetria diretamente das NF produtoras, atuando como ponto focal que reduz a fragmentação e evita a

formação de silos de dados. A partir dessas informações, o sistema aplica modelos de *Machine Learning* (ML) para gerar inferências, que são disponibilizadas novamente às funções consumidoras. Essa centralização da análise permite que a rede tome decisões de forma mais proativa, como ajustar parâmetros operacionais ou otimizar rotas com base em previsões (GARCIA et al., 2023). Entretanto, essa mesma abordagem traz desafios importantes de escalabilidade e de latência, já que concentrar o processamento de grandes volumes de dados em um único ponto pode gerar gargalos, especialmente em aplicações que exigem respostas em tempo real. Isso torna necessária uma arquitetura interna capaz de separar o processamento mais intensivo, para um rápido retorno de resultados (3GPP, 2023a).

Arquitetura da NWDAF

A arquitetura interna da NWDAF foi planejada para separar o peso computacional entre o treinamento e a execução dos modelos, de modo a lidar com o alto volume de dados sem comprometer o desempenho do sistema. A separação formal foi consolidada no Release 17, com a divisão da NWDAF em duas instâncias lógicas principais: a *Model Training Logical Function* (MTLF) e a *Analytics Logical Function* (AnLF) (3GPP, 2023a). A MTLF é responsável por processar dados históricos e treinar algoritmos de IA. Já a AnLF atua como o motor de inferência, utilizando os modelos treinados para analisar a telemetria em tempo real e fornecer respostas rápidas às solicitações das demais NF do 5GC (3GPP, 2023a). No Release 18, essa estrutura foi ainda estendida pelo conceito de NWDAF federada, no qual múltiplas instâncias de MTLF cooperam no treinamento distribuído de modelos sem a necessidade de centralizar dados sensíveis, abrindo caminho para inteligência analítica colaborativa entre domínios.

A sustentação dessa malha analítica depende de componentes de apoio voltados à gestão eficiente de dados. Na Figura 1, é possível obter uma visão do fluxo de coleta, processamento e exposição analítica do 5GC. A *Data Collection Coordination Function* (DCCF) atua como uma mediadora inteligente, organizando o fluxo de informações para evitar sobrecarga nas fontes originais. Já a *Analytics Data Repository Function* (ADRF) fornece o armazenamento persistente necessário para que o histórico da rede possa ser reutilizado em ciclos de melhoria contínua (3GPP, 2023a). As fontes de dados abrangem praticamente todas as funções do 5GC, incluindo a AMF, a SMF, a *Policy Control Function* (PCF), a *Unified Data Management* (UDM) e os sistemas de *Operations, Administration and Maintenance* (OAM). A comunicação entre esses elementos ocorre por meio de serviços expostos via API, como o *Nnwdaf_AnalyticsInfo*, voltado para requisições síncronas, e o *Nnwdaf_EventsSubscription*, utilizado para monitoramento assíncrono baseado em notificações (3GPP, 2023c; GARCIA et al., 2023). Em uma camada superior, *frameworks* como o *Zero-touch Network* (ZSM) da ETSI (ETSI, 2019) complementam o ecossistema 3GPP ao definir princípios de automação fim-a-fim e gerenciamento autônomo entre domínios, fornecendo a base conceitual para a articulação da NWDAF com mecanismos de orquestração mais amplos.




Figura 1: Fluxo de coleta, processamento e exposição analítica na arquitetura 5GC e NWDAF.

2.2 Rede de Acesso de Rádio e Open RAN

A RAN é responsável por conectar os dispositivos dos usuários (UE) à infraestrutura da operadora por meio da comunicação sem fio. Nas arquiteturas mais tradicionais, essa camada era construída com soluções proprietárias e verticalmente integradas, o que dificultava a interoperabilidade entre fabricantes e limitava a flexibilidade da rede. Com o surgimento da O-RAN, esse modelo foi substituído por uma arquitetura aberta e desagregada, que permite maior modularidade e virtualização dos componentes da rede (ALLIANCE, 2022; POLESE et al., 2023).

Como ilustrado na Figura 2, a arquitetura O-RAN divide a estação rádio-base em três unidades principais: (i) *Radio Unit* (RU), (ii) DU e (iii) CU, seguindo o modelo de divisão funcional originalmente proposto pelo 3GPP TR 38.801 e adotando, especificamente, o *split 7.2x* entre RU e DU (3GPP, 2017; ALLIANCE, 2022). A RU é responsável pelas funções relacionadas à transmissão rádio, incluindo o processamento de sinais e a comunicação direta com dispositivos móveis. A DU, por sua vez, executa funções de processamento em tempo real, como o escalonamento de recursos, o controle de acesso ao meio e parte do processamento da camada física. Por fim, a CU centraliza funções de controle e gerenciamento de sessões, separando as tarefas críticas de baixa latência das funções de controle mais centralizadas. Essa separação facilita a distribuição de processamento ao longo da rede e permite que diferentes componentes sejam implementados por fornecedores distintos. A desagregação cria um ambiente mais adequado para a introdução de mecanismos inteligentes de automação, especialmente os baseados em IA.

O gerenciamento da arquitetura é realizado pelo *RAN Intelligent Controller* (RIC) (*RAN Intelligent Controller*), responsável por coordenar funções inteligentes em diferentes escalas de tempo. No topo da hierarquia apresentada na Figura 2, encontra-se o domínio de Gerencia-

mento e Orquestração de Serviços (*SMO*), que abriga o *Non-RT RIC*, padronizado pelo O-RAN WG2 (O-RAN ALLIANCE, 2023b). Essa camada não opera em tempo real, tipicamente com atraso superior a um segundo, e concentra funções estratégicas, como a coleta de dados da rede, o treinamento de modelos de IA, a definição de políticas globais e o gerenciamento de aplicações chamadas *rApps*. Essas aplicações são voltadas para otimizações em horizontes de não tempo real, atuando em tarefas como previsão de tráfego, planejamento de capacidade espectral, análise de desempenho e gerenciamento de fatias de rede. Como possuem maior tolerância à latência, essas aplicações conseguem utilizar modelos de aprendizado mais complexos e análises históricas mais extensas.




Figura 2: Arquitetura Open RAN destacando a desagregação da estação rádio base e os níveis de controle do RIC.

Os modelos treinados no *Non-RT RIC* podem ser transferidos para camadas inferiores da arquitetura por meio da interface A1, mostrada na Figura 3. Essa interface permite o envio de políticas de controle, parâmetros de otimização e *enrichment information* ao *Near-RT RIC*. Em fluxos de IA/ML padronizados pela O-RAN ALLIANCE (O-RAN ALLIANCE, 2023a), modelos treinados também podem ser distribuídos para inferência próxima à borda. O formato do modelo (por exemplo, `.tf` ou `ONNX`) depende do fluxo de implantação adotado, priorizando a inferência leve e eficiente em ambientes próximos à borda da rede.

Abaixo do domínio de orquestração está o *Near-RT RIC*, padronizado pelo O-RAN WG3

(O-RAN ALLIANCE, 2023c) e responsável por decisões com requisitos temporais mais rígidos, normalmente entre 10 milissegundos e 1 segundo. Nessa camada são executadas aplicações chamadas *xApps*, que atuam diretamente sobre as condições instantâneas da rede rádio. Enquanto as *rApps* realizam otimizações estratégicas, as *xApps* executam ações táticas quase em tempo real. Na arquitetura apresentada na Figura 3, os mecanismos de inferência de IA estão integrados às próprias *xApps*, permitindo que decisões sejam tomadas localmente a partir dos dados recebidos da rede. Isso possibilita implementar funcionalidades como balanceamento de carga, controle adaptativo de potência, otimização espectral e direcionamento inteligente de feixes (*beamforming*).

A comunicação entre o *Near-RT RIC* e os elementos da RAN ocorre por meio da interface E2, estruturada em torno do protocolo E2AP e de *Service Models* (*E2 Service Model* (E2SM)), tais como *Key Performance Measurements* (KPM), *RAN Control* (RC) e *Network Interface* (NI) (ALLIANCE, 2022; POLESE et al., 2023). Por meio desses modelos, métricas operacionais e informações de telemetria são continuamente coletadas das unidades da rede, e comandos de controle podem ser enviados às unidades DU e CU. Dessa forma, as *xApps* conseguem monitorar o estado da rede e reagir dinamicamente às mudanças nas condições do ambiente rádio. No plano de execução em tempo real, localizado principalmente na DU, os mecanismos inteligentes precisam operar com latências extremamente baixas. Nesse cenário, técnicas de IA podem ser utilizadas para prever o estado do canal de rádio, otimizar o agendamento de pacotes e melhorar a eficiência do uso espectral em intervalos muito curtos de tempo. O *Non-RT RIC* atua como camada estratégica responsável pelo treinamento e pela distribuição de modelos, e o *Near-RT RIC* executa inferências e decisões de controle quase em tempo real por meio das *xApps*. Já no domínio da RAN, as unidades DU e CU recebem comandos e fornecem métricas operacionais continuamente por meio da interface E2, criando um ciclo de otimização contínuo entre treinamento, inferência e execução.

2.3 Agentes Inteligentes e Redes Baseadas em Intenção

O gerenciamento autônomo de redes se baseia no paradigma de IBN, que pode ser entendido como um conjunto de mecanismos capazes de traduzir objetivos de alto nível em configurações de rede executáveis, sem a necessidade de intervenção manual detalhada (3GPP, 2023b; TM Forum, 2022). Esse conceito muda a forma como a infraestrutura é administrada, ao priorizar o resultado desejado pelo operador, chamado “intenção”, em vez de depender de configurações manuais tradicionais. Uma intenção pode ser descrita como uma declaração formal de metas e restrições, por exemplo, a definição de uma latência máxima para uma determinada fatia de rede. A partir disso, o sistema deve ser capaz de interpretar essa intenção, convertê-la em políticas operacionais e garantir seu cumprimento contínuo por meio de mecanismos de verificação e ajuste. Esse processo é sustentado por laços de garantia em malha fechada (*closed-loop assurance*), conceitualmente alinhados ao modelo Monitor-Analyze-Plan-Execute over a




Figura 3: Arquitetura da integração de IA no ecossistema O-RAN utilizando Non-RT RIC e Near-RT RIC.

shared Knowledge (MAPE-K), originalmente proposto no contexto de *Autonomic Computing* (KEPHART; CHESS, 2003) e formalizado para o domínio de telecomunicações pelo *framework* ZSM da *European Telecommunications Standards Institute* (ETSI) (ETSI, 2021; BRODIMAS et al., 2025).

A execução desse modelo depende do uso de agentes inteligentes, que podem ser definidos como entidades computacionais autônomas capazes de perceber o ambiente por meio de sensores e de atuar sobre ele por meio de atuadores, com o objetivo de alcançar metas específicas de forma racional (RUSSELL; NORVIG, 2010). No contexto do 5GC, tanto as NF tradicionais quanto os novos controladores podem ser interpretados como partes de um sistema orientado a agentes. Nesse cenário, a NWDAF pode ser vista como um agente voltado à análise e geração de conhecimento, enquanto funções como AMF e SMF atuam como agentes responsáveis pelo contexto e pela execução de sessões. Já os *xApps* do RIC operam como agentes de controle local em tempo quase real. Essa forma de modelagem permite descrever o comportamento da rede com base na arquitetura de Crença-Desejo-Intenção (*BDI - Belief-Desire-Intention*), formalizada computacionalmente por Rao e Georgeff (RAO; GEORGEFF, 1995) a partir da teoria filosófica da ação prática proposta por Bratman (BRATMAN, 1987). Nesse modelo, as crenças correspondem ao estado da rede obtido via telemetria, os desejos representam os objetivos de desempenho (como os SLA) e as intenções dizem respeito aos planos de ação escolhidos para a execução.

Sistemas multiagentes

A operação coordenada de uma rede autônoma exige ir além de agentes isolados, evoluindo para a estrutura de um MAS. Um MAS pode ser entendido como um sistema composto por múltiplos agentes independentes que interagem, cooperam e, quando necessário, negociam entre si para resolver problemas complexos que não poderiam ser tratados por uma única entidade (WOOLDRIDGE, 2009; BARIAH et al., 2024a). Nesse contexto, a SBA do 5G atua como o *middleware* que viabiliza essa interação. Por meio do seu barramento de serviços, torna-se possível a troca contínua de informações entre agentes distribuídos tanto no núcleo quanto na borda da rede, o que permite uma atuação coordenada e mais eficiente.

A comunicação e a coordenação entre esses agentes são estruturadas por protocolos de interação que definem como solicitações de serviço e notificações de eventos são tratadas. Em geral, o modelo de requisição e resposta (*request-response*) é utilizado em tarefas mais deliberativas, como consultas à NWDAF, enquanto o modelo de publicação e assinatura (*publish-subscribe*) atende melhor à disseminação assíncrona de informações. Esse segundo modelo permite que os agentes reajam dinamicamente a mudanças no ambiente (EHTESHAM et al., 2025). A adoção de sistemas distribuídos contribui para aumentar a resiliência e a escalabilidade da rede. Por outro lado, apresenta também desafios relacionados ao consenso e à consistência das decisões entre os agentes. Por isso, torna-se necessário o uso de protocolos de comunicação interativos bem definidos, capazes de evitar inconsistências e prevenir a degradação do desempenho do sistema como um todo (BARIAH et al., 2024a).

Agentic Serving Definido por Software

O escalonamento de sistemas compostos por múltiplos agentes demanda um paradigma de infraestrutura que vai além do simples roteamento de dados. Nesse contexto, propostas recentes, como o *Software-Defined Agentic Serving* (AGARWAL et al., 2026), sugerem aplicar os princípios de SDN à camada de inteligência, separando a lógica de raciocínio da mecânica de comunicação entre os agentes. Trata-se de uma proposta emergente, ainda em fase de consolidação na literatura, que estrutura a infraestrutura de agentes em torno de três planos operacionais: o Plano de Dados, responsável pelo fluxo de informações; o Plano de Métricas, voltado à coleta e análise de indicadores; e o Plano de Controle, que coordena as decisões e o comportamento do sistema como um todo.

Na Figura 4, observa-se que cada um desses planos está mapeado para componentes e funções específicas da rede, atuando como agentes no modelo *Belief-Desire-Intention* (BDI). No mapeamento proposto por Agarwal et al. (AGARWAL et al., 2026), o Plano de Dados atua como uma camada de adaptação (*shim layer*), representada pelas *xApps*, permitindo ajustar dinamicamente a granularidade das mensagens. Com isso, a troca de informações entre agentes pode alternar entre fluxos contínuos de dados (*streaming*) e processamento em lote (*batching*),

de acordo com as condições e a carga da rede. O Plano de Métricas é associado a funções de observabilidade do 5GC, exercidas em conjunto pela SMF, AMF e pelas próprias capacidades analíticas da NWDAF, oferecendo visibilidade unificada sobre o comportamento do sistema em tempo real. Por sua vez, o Plano de Controle, associado à NWDAF, atua como elemento central de orquestração, interpretando as intenções do operador e definindo regras de roteamento e priorização durante a execução (*runtime*). Essa abordagem, ainda que conceitual, sugere que os MAS podem operar de forma mais resiliente, otimizando a vazão de processamento e contribuindo para a manutenção dos SLA em ambientes dinâmicos e de alta variabilidade, como o 5GC e a O-RAN (AGARWAL et al., 2026).

Model Context Protocol

A coordenação efetiva entre agentes inteligentes em sistemas distribuídos exige não apenas a definição de papéis e responsabilidades, mas também um mecanismo padronizado para que os agentes descubram e invoquem capacidades externas em tempo de execução. Nesse contexto, o MCP foi proposto como um protocolo aberto de comunicação entre modelos de linguagem e ferramentas externas, estruturado sobre uma arquitetura cliente-servidor (EHTESHAM et al., 2025). No modelo MCP, cada conjunto de capacidades, como a consulta a uma API de rede ou a leitura de métricas de telemetria, é exposto por um servidor MCP, enquanto o agente LLM atua como cliente, descobrindo dinamicamente as ferramentas disponíveis e invocando elas por meio de chamadas estruturadas em *JavaScript Object Notation* (JSON), sem que o retreinamento ou ajuste fino do modelo base seja necessário.




Figura 4: Representação do Agentic Serving e sistemas multiagentes no 5GC.

2.4 Grandes Modelos de Linguagem

Os LLM são redes neurais profundas baseadas na arquitetura *Transformer*, conhecidas por sua capacidade de processar e gerar linguagem complexa por meio do mecanismo de autoatenção (*self-attention*) (VASWANI et al., 2017; ZHOU et al., 2024). No contexto das telecomunicações, esses modelos vêm sendo utilizados como motores de raciocínio para agentes inteligentes, principalmente por sua capacidade de generalização e por atuarem como tradutores semânticos entre o operador humano e a infraestrutura de rede (BARIAH et al., 2024b; ZOU et al., 2024). A adoção dos LLM se justifica, em grande parte, pela limitação das abordagens baseadas em regras, que tendem a não escalar bem em cenários mais complexos, especialmente quando há alta variabilidade linguística nas intenções e múltiplas interdependências entre os componentes da rede. Diferentemente dos modelos tradicionais de ML, os LLM podem atuar como planejadores (*planners*), decompondo objetivos mais abstratos em sequências de ações, como chamadas de API, além de utilizar ferramentas externas para validar e executar configurações, conforme padrões estabelecidos por trabalhos como *ReAct* (YAO et al., 2023) e *Toolformer* (SCHICK et al., 2023). Estratégias complementares, como *Retrieval-Augmented Generation* (LEWIS et al., 2020), têm sido empregadas para mitigar o fenômeno da alucinação, ancorando as respostas dos modelos em bases de conhecimento atualizadas (JIANG et al., 2025; ZHOU et al., 2024).

Fundamentos da inferência distribuída e desagregação

A implementação de LLM em redes de missão crítica traz desafios importantes relacionados ao desempenho e à latência. Nesse contexto, abordagens modernas de *serving* para esses modelos defendem a desagregação do processo de inferência, considerando que a geração de respostas envolve etapas com perfis computacionais bastante distintos (KWON et al., 2023; PATEL et al., 2024; SOLO.IO; HAT, 2026; ZHOU et al., 2024). A etapa inicial, conhecida como *prefill*, caracteriza-se pelo processamento intensivo do *prompt* e pela construção do cache de Chave-Valor (*KV Cache*), limitada principalmente pela capacidade computacional. Já a fase seguinte, chamada de *decode*, é responsável pela geração autorregressiva dos *tokens* de saída, limitada principalmente pela largura de banda de memória. *Frameworks* de *serving*, como *vLLM* (KWON et al., 2023), popularizaram técnicas como *PagedAttention* para o gerenciamento eficiente do cache KV, enquanto trabalhos como *Splitwise* (PATEL et al., 2024) demonstraram que a separação física entre as etapas de *prefill* e *decode* pode trazer ganhos significativos de eficiência energética e de vazão.

A arquitetura de inferência distribuída permite que essas etapas sejam executadas em recursos computacionais distintos e especializados. Com essa separação, o sistema passa a gerenciar de forma independente o escalonamento das cargas de trabalho, além de controlar a movimentação do *KV Cache* entre diferentes nós por meio de redes de alta velocidade. Essa modularidade é essencial para evitar que o processamento associado ao raciocínio dos agentes de IA dispute

recursos de maneira prejudicial com as funções críticas da rede no 5GC, contribuindo para um uso mais equilibrado e eficiente da infraestrutura (SOLO.IO; HAT, 2026).

Ambientes de execução efêmeros e mobilidade de estado

A segurança e a mobilidade dos agentes inteligentes na topologia *Core-Edge* exigem um ambiente computacional que suporte execuções voláteis e, ao mesmo tempo, garanta isolamento rigoroso. Nesse contexto, os ambientes de execução efêmeros, baseados em tecnologias como o *WebAssembly* (*Wasm*), oferecem um *sandbox* seguro para a execução de código gerado por IA, sem comprometer a integridade do sistema hospedeiro (BNEB, 2026). Esse modelo se alinha aos princípios de confiança zero (*zero-trust*), impondo isolamento estrito por meio de *sandboxing* e controle granular de *capabilities* por meio de interfaces como *WASI*, evitando o consumo excessivo de processamento e memória por agentes cujas ações são geradas dinamicamente.

Uma característica importante desses *runtimes* é a capacidade de serializar e migrar o estado de execução do agente, incluindo memória linear, registradores de pilha e contexto associado, o que pode ser interpretado como sua memória ativa e viabiliza a mobilidade entre o núcleo e a borda da rede. Esse ecossistema de inferência distribuída e suporte à mobilidade é sintetizado na Figura 5, que ilustra como as fases de *prefill* (no 5GC) e *decode* (na borda) operam em conjunto com a migração do *KV cache*, tudo isso sob o isolamento provido pela camada *Wasm Sandbox*. Como consequência, o agente pode executar decisões localmente, por exemplo, no nível de rádio, com menor latência, reduzindo os riscos associados a inconsistências ou “alucinações” e contribuindo para uma operação autônoma mais confiável (BNEB, 2026).




Figura 5: Desagregação de inferência de LLM, migração de KV Cache e isolamento via Wasm no contínuo Core-Edge.

Apesar dos avanços na virtualização do núcleo 5G, na padronização da SBA e na incorporação de capacidades analíticas por meio da NWDAF, a coordenação efetiva de inteligência distribuída entre o núcleo e a borda ainda enfrenta limitações relevantes. Em muitos casos, a

literatura trata de forma isolada aspectos como comunicação, coordenação e mobilidade de estado entre agentes, o que evidencia a ausência de uma abordagem mais integrada que considere, ao mesmo tempo, requisitos de latência, consistência e isolamento em ambientes de missão crítica. Além disso, embora os LLMs tenham ganhado destaque como possíveis orquestradores de decisões complexas, sua integração com arquiteturas de rede ainda está em fase de consolidação. Questões relacionadas ao *serving* eficiente e à execução segura em ambientes distribuídos permanecem em aberto, especialmente diante dos desafios práticos de implantação em cenários reais.

Esse cenário evidencia uma lacuna na definição de uma arquitetura de referência que articule, de forma conjunta, (i) redes baseadas em intenção com semântica formal de intenção, (ii) sistemas multiagentes apoiados por protocolos de coordenação adequados a SLA estritos, e (iii) infraestruturas de inferência distribuída de LLM com mobilidade segura de estado entre o núcleo e a borda da rede. É nesse contexto que se posiciona a proposta deste trabalho, que busca investigar mecanismos para a comunicação e a orquestração de agentes em redes 5G, procurando alinhar os avanços recentes em IA às restrições operacionais típicas das telecomunicações modernas.

Com base nos fundamentos apresentados, este capítulo delineou a transição para uma rede 5G orientada por IA distribuída, na qual a rigidez das configurações manuais dá lugar à flexibilidade proporcionada por agentes inteligentes e sistemas multiagentes. A estrutura teórica que articula o 5GC, a arquitetura O-RAN e as capacidades cognitivas dos LLM permite estabelecer os principais requisitos para a construção de um sistema de gerenciamento baseado em intenções. Além disso, conceitos como a desagregação da inferência e o uso de ambientes de execução seguros fornecem a infraestrutura necessária para viabilizar essa abordagem em cenários reais, com potencial de aplicação em escala de produção. No capítulo seguinte, os elementos discutidos aqui servem de base para a definição da metodologia adotada na implementação e na validação do sistema proposto.

3 TRABALHOS RELACIONADOS

Este capítulo apresenta uma revisão sistemática da literatura que constitui a base comparativa para a análise de soluções de orquestração baseadas em MAS e LLM aplicadas aos ecossistemas 5GC e O-RAN. A seleção dos trabalhos reflete o estado da arte em automação cognitiva e gerenciamento orientado a intenções, permitindo identificar as principais lacunas metodológicas, os desafios de implementação física e as tendências de arquiteturas híbridas e distribuídas. Com o objetivo de contextualizar a pesquisa dentro do panorama científico atual, foram realizadas consultas nas bases de dados *Science Direct*, *IEEE Xplore* e *arXiv*. Foram empregadas strings de busca direcionadas, tais como: "multi-agent" AND "LLM" AND "5G core" AND "RAN orchestration", além de "intent-based networking" AND "O-RAN", cujos resultados foram submetidos a triagem por relevância temática, recência e qualidade do veículo de publicação. Os dezessete trabalhos selecionados, identificados pelos índices A01 a A17, estão listados na Tabela 1, que apresenta, para cada publicação, o índice de referência utilizado ao longo deste capítulo, os autores, o título e o ano de publicação.

Os trabalhos podem ser entendidos através de cinco eixos temáticos que representam os pilares da atual automação de redes: (i) IBN focado em análises da função NWDAF, (ii) a orquestração dinâmica e fatiamento de rede (*network slicing*), (iii) o uso de IA na borda e na RAN, (iv) o diagnóstico autônomo de falhas guiado por LLM e (v) os protocolos semânticos juntamente de revisões sistemáticas e *surveys*.

Nas seções a seguir, cada um desses trabalhos é analisado individualmente. Foca-se em extrair a arquitetura proposta por cada autor(es), as metodologias de linguagem, bem como os resultados obtidos em seus testes de desempenho. Dessa forma, será possível identificar as limitações das abordagens atuais, como os desafios associados a modelos muito pesados, e isso servirá de justificativa para as escolhas arquiteturais propostas no desenvolvimento desse trabalho.

3.1 *Intent Based Networking* e análises NWDAF

O primeiro eixo temático se concentra na junção das IBN e da NWDAF no ecossistema 5G e nas futuras redes *Sixth Generation* (6G). O uso das IBN representa uma mudança de paradigma fundamental na orquestração de redes, buscando substituir as configurações manuais baseadas em regras por diretrizes descritas em linguagem natural, de modo que a rede atenda a esses objetivos de forma automatizada e dinâmica. No centro dessa inteligência analítica está a NWDAF. Os trabalhos agrupados investigam como os LLM podem extrair e interpretar semanticamente intenções e anomalias de usuários diretamente do 5GC, até a proposta de *frameworks* de agentes construídos para traduzir essas intenções em invocações reais e complexas.

Manias et al. (2024) apresentam um dos primeiros trabalhos a explorar o uso de LLMs para

Índice	Autores	Título	Ano
A01	TAHENNI et al.	A Survey on 6G and O-RAN Intelligence: Semantic Protocols, Protocol Learning, and AI-Enabled Semantic Protocols	2026
A02	PELLEJERO et al.	Agentic AI for Mobile Network RAN Management and Optimization	2025
A03	HE et al.	Agentic AI-RAN: Enabling Intent-Driven, Explainable and Self-Evolving Open RAN Intelligence	2026
A04	AMEUR; BRIK; KSENTINI	Agentic-NWDAF: Enabling Intent-Driven Agentic Intelligence for Autonomous 6G Network Analytics Management	2026
A05	MOREIRA et al.	AGORA: Agentic Green Orchestration Architecture for Beyond 5G Networks	2026
A06	YU et al.	CORE: Toward Ubiquitous 6G Intelligence Through Collaborative Orchestration of Large Language Model Agents Over Hierarchical Edge	2026
A07	MEKRACHE et al.	DMO-GPT: An Intent-Driven Framework for Distributed 6G Management and Orchestration	2026
A08	SOLIMAN et al.	IntAgent: NWDAF-Based Intent LLM Agent Towards Advanced Next Generation Networks	2026
A09	WEI et al.	Large Language Models for Next-Generation Wireless Network Management: A Survey and Tutorial	2025
A10	DANDOUSH et al.	Large Language Models meet Network Slicing Management and Orchestration	2024
A11	SHI et al.	Leveraging Multi-Agent System (MAS) and Fine-Tuned Small Language Models (SLMs) for Automated Telecom Network Troubleshooting	2025
A12	QAYYUM et al.	LLM-Driven Multi-Agent Architectures for Intelligent Self-Organizing Networks	2025
A13	KAN et al.	Mobile-LLaMA: Instruction Fine-Tuning Open-Source LLM for Network Analysis in 5G Networks	2024
A14	GEMAYEL; MOKH	Network Function Orchestration with LLM-based Multi-Agent System	2025
A15	KHOLMATOV et al.	Toward AI-on-RAN: Enabling on-RAN Edge Intelligence for AI-Native 6G Networks	2026
A16	MANIAS et al.	Towards Intent-Based Network Management: Large Language Models for Intent Extraction in 5G Core Networks	2024
A17	BANDARA et al.	Slice-MCP: Fine-Tuned Llama-4 LLM and MCP Enabled 5G Network Slice Orchestration Platform	2025

Tabela 1: Lista dos artigos selecionados.

extração de intenções no contexto do núcleo de redes 5G. Os autores desenvolvem um modelo customizado baseado no ChatGPT 3.5, configurado por meio de técnicas de *prompting*, com o objetivo de classificar requisições de operadores em seis categorias de intenções definidas pelo padrão 3GPP TS 28.312: *Deployment Intent*, *Modification Intent*, *Performance Assurance In-*

tent, *Intent Report Request*, *Intent Feasibility Check* e *Regular Notification Request*. O modelo recebe como contexto trechos das especificações técnicas do 3GPP e demonstra capacidade de identificar múltiplos *intents* presentes em uma mesma requisição, além de justificar suas classificações, incorporando, assim, um grau de explicabilidade ao processo. Os autores reconhecem como limitação o uso de um modelo de código fechado e indicam como trabalho futuro a transição para LLMs de código aberto e a realização de *fine-tuning* com *datasets* específicos do domínio do *core*.

Kan et al. (2024) propõem o Mobile-LLaMA, um LLM de código aberto especializado em análise de redes móveis, desenvolvido por meio de *instruction fine-tuning* do modelo LLaMA 2 de 13B. O treinamento utiliza 15.000 pares de instrução-saída distribuídos em três funções principais: análise de roteamento IP, análise de pacotes e análise de desempenho de rede, com dados coletados de conjuntos de dados públicos e expandidos por meio do método *self-instruct* com auxílio do GPT da OpenAI. Para viabilizar o treinamento em *hardware* acessível, os autores adotam a técnica *Low-Rank Adaptation* - (*Low-Rank Adaptation* (LoRA)). O Mobile-LLaMA é proposto como componente da função NWDAF, capaz de gerar *scripts* em Python que executam análises específicas de rede, utilizando bibliotecas especializadas como PyBGPStream, Scapy e Pandas. Em avaliação comparativa com o GPT-3.5 e modelos base do LLaMA 2, o Mobile-LLaMA alcança pontuação de 247 em 300 pontos no *benchmark* desenvolvido pelos autores, superando o GPT-3.5, especialmente na tarefa de análise de roteamento IP, na qual obtém 97 pontos contra 49.

Ameur, Brik e Ksentini (2026) introduzem o Agentic-NWDAF, um *framework* multiagente baseado em Inteligência Artificial Agêntica que traduz intenções em linguagem natural de sistemas de suporte a operações *Operations Support System* (OSS) em chamadas executáveis às APIs da NWDAF. O sistema é composto por sete agentes com funções especializadas, *Chatbot*, *Planner*, *API Selector*, *Payload Generation*, *Validator*, *Executor* e *Monitoring*, que colaboram de forma autônoma para interpretar, planejar e executar as intenções do operador. Uma contribuição central do trabalho é a utilização do MCP, protocolo desenvolvido pela Anthropic, que permite aos agentes acessar dinamicamente a documentação das APIs do 3GPP sem necessidade de retreinamento ou *fine-tuning* dos modelos. A implementação utiliza a plataforma CrewAI para orquestrar agentes e modelos LLM hospedados localmente via Ollama. A avaliação é realizada sobre um *benchmark* de 100 intenções NWDAF derivadas de especificações técnicas do 3GPP, com modelos do tipo *reasoning*, como DeepSeek-R1-14B e GPT-OSS-20B, alcançando taxas de sucesso de tarefas entre 85% e 90% e acurácia de seleção de ferramentas de até 95%.

Soliman et al. (2026) apresentam o IntAgent, um agente LLM integrado diretamente ao motor de *analytics* da NWDAF para o cumprimento autônomo de intenções de operadores de rede. Diferentemente de abordagens que tratam a NWDAF como interface externa, os autores desenvolvem uma *Intent Tools Engine* incorporada ao próprio motor analítico da NWDAF, expondo ferramentas via MCP que abrangem análise de *Key Performance Indicatorss* (KPIs),

verificação de viabilidade, gerenciamento de sessões, controle de políticas e monitoramento temporal. O agente utiliza o modelo Meta LLaMA 3.1 com 8 bilhões de parâmetros, executado localmente via Ollama, e acessa as ferramentas por meio de um cliente MCP. O sistema é validado por meio de dois casos de uso práticos em um ambiente de rede implementado com Open5GS e UERANSIM: o primeiro consiste na predição da utilização de memória de um *slice* de rede utilizando um modelo *Random Forest*, e o segundo envolve o agendamento e a aplicação automática de uma política de aumento da taxa de dados para um *slice* de *streaming* em um intervalo de tempo específico. Os autores reconhecem como limitações a ocorrência de alucinações do modelo e a geração de ciclos de raciocínio excessivamente longos mesmo para tarefas de baixa complexidade.

3.2 Orquestração dinâmica e *Network Slicing*

A orquestração dinâmica e o fatiamento de rede são recursos fundamentais para que o 5G forneça redes virtuais customizadas e isoladas sobre uma infraestrutura física compartilhada. Embora o fatiamento de rede ofereça a flexibilidade para atender a casos heterogêneos (incluindo comunicação de ultrabaixa latência até implementações de *Internet of Things* (IoT)), a orquestração de ponta a ponta dessas fatias impõe desafios operacionais. Os trabalhos listados nesta seção demonstram como os LLM e os MAS vêm sendo aplicados para abstrair essa complexidade, cobrindo domínios que vão desde o núcleo da rede (5GC) até a RAN e a borda da infraestrutura, distinção que se tornará central na proposta deste trabalho, o qual foca especificamente na orquestração hierárquica entre o CN-NSSMF, responsável pelas funções de núcleo, e o RAN-NSSMF, responsável pelos recursos de acesso rádio. A literatura examinada ilustra como as intenções descritas em linguagem natural pelos usuários podem ser traduzidas, de forma autônoma, para instâncias de fatias de rede e para descritores de serviço padronizados. Dentre as inovações discutidas, destacam-se o uso do MCP para acionar a API de implementação de fatias de rede, o emprego de roteadores semânticos baseados em especificações normativas da 3GPP para evitar alucinações durante a execução de tarefas e o desenvolvimento de *frameworks* distribuídos para múltiplos operadores de rede.

Dandoush et al. (2024) propõem uma visão conceitual de gerenciamento de fatiamento de rede ponta a ponta potencializado por LLM e MAS. Os autores definem um arcabouço composto por quatro tipos de agentes LLM mapeados às funções de gerenciamento padronizadas pela ETSI e pela 3GPP: agente no dispositivo, agente de modelagem de fatia, agente de implantação de fatia e agente de gerenciamento de recursos. Cada agente é equipado com ferramentas próprias e responsável por uma etapa distinta do ciclo de vida da fatia, cobrindo desde a tradução da intenção do usuário até a geração automática de descritores *Topology and Orchestration Specification for Cloud Applications* (TOSCA)/*YAML Ain't Markup Language* (YAML) e a implantação via *NFV Orchestrator* (NFV-O). O trabalho argumenta que, ao distribuir a lógica de orquestração em múltiplos domínios administrativos, os agentes podem superar as limitações

de interoperabilidade e de alocação de recursos impostas pelas abordagens centralizadas de SDN/NFV. Por ser um trabalho de caráter prospectivo, os autores reconhecem como limitações a ausência de validação experimental, a necessidade de conjuntos de dados representativos para ajuste fino dos modelos e a carência de padrões de interoperabilidade que regulem a comunicação entre agentes em diferentes domínios.

Gemayel e Mokh (2025) introduzem um *framework* de orquestração dinâmica de funções de rede baseado em MAS e em raciocínio via *Chain of Thought* (CoT). Os autores propõem uma sequência de três agentes especializados: um Roteador Semântico, responsável por direcionar as requisições do usuário ao domínio administrativo correto; um Tradutor de Intenções, que gera planos estratégicos ancorados em uma base de conhecimento contendo especificações da 3GPP, mitigando alucinações por ancoragem normativa; e um Resolvedor, que seleciona e executa as funções de rede necessárias para cumprir o plano estratégico. Os resultados demonstram que a cadeia de agentes consegue adaptar-se dinamicamente a cenários complexos de orquestração em ambientes multi-domínio. Os autores reconhecem como limitações a dependência de bases de conhecimento 3GPP atualizadas para o correto funcionamento do Tradutor de Intenções e os desafios de escalabilidade do *pipeline* em ambientes com um grande número de domínios administrativos simultâneos.

Mekrache et al. (2026) propõem o DMO-GPT, um *framework* orientado a intenções para gerenciamento e orquestração distribuídos em redes 6G. Os autores arquitetam uma interface baseada em LLM que recebe intenções expressas em linguagem natural pelos operadores e as decompõe em chamadas ordenadas de API, coordenando domínios heterogêneos de infraestrutura de rede por meio de um sistema de suporte a operações (OSS). O *framework* demonstra capacidade de traduzir objetivos de alto nível em sequências executáveis de operações em múltiplos domínios administrativos, contribuindo para a automação ZSM em cenários 6G. Os autores reconhecem como limitações a dependência da qualidade das especificações de intenção fornecidas pelos operadores e os desafios de validação em ambientes de produção, em domínios reais e com múltiplos fornecedores.

Moreira et al. (2026) propõem o AGORA (*Agentic Green Orchestration Architecture*), uma arquitetura de orquestração agnética orientada à sustentabilidade para redes *Beyond 5G*. Os autores embarcam um agente LLM local com chamadas a ferramentas no laço de controle da rede móvel, traduzindo intenções de sustentabilidade expressas em linguagem natural em ações telemetria-fundamentadas sobre a UPF, realizando roteamento de tráfego consciente de energia entre instâncias de MEC. A arquitetura foi avaliada com quatro LLM locais, OLMoE, Qwen 2.5, Mistral e Phi 3.5, em um ambiente experimental com núcleo 5G free5GC sobre Kubernetes. Qwen 2.5 (1,5B) obteve o melhor compromisso entre energia e latência, sendo o único modelo a apresentar comportamento de migração não nulo sob a política de limiar de potência. Os autores reconhecem como limitações a cobertura restrita do espaço de intenções testado, a dependência de modelos locais com capacidade confiável de *tool-calling* e a ausência de validação com sinais de intensidade de carbono e políticas de múltiplas fatias.

Bandara et al. (2025) apresentam o Slice-MCP, a primeira plataforma de orquestração de fatias 5G baseada no MCP, integrando o protocolo ao LLM Llama-4, ajustado por *fine-tuning*, para automação orientada à linguagem natural. Os autores definem uma arquitetura em cinco camadas, serviços do núcleo 5G, orquestração de fatias, camada MCP, camada LLM e camada de agentes LLM, na qual o modelo Llama-4, ajustado via *Quantized Low-Rank Adaptation* (QLoRA) com a biblioteca Unsloth sobre conjuntos de dados sintéticos de pares intenção-função mapeia consultas em linguagem natural para chamadas MCP estruturadas, com funções como `deploySlice`, `configureCoreServices` e `allocateNetworkResources`, e coordena automaticamente NSMF e NSSMF. A plataforma foi validada em um ambiente experimental real com múltiplos núcleos do Open5GS sobre a nova RAN da Ericsson, demonstrando redução significativa da complexidade operacional e alta fidelidade no mapeamento intenção-função. Os autores reconhecem como limitações a dependência de dados de treinamento sintéticos, que podem não cobrir a totalidade dos cenários de produção, e a necessidade de expandir o suporte a modelos de código aberto adicionais com estratégias de ajuste fino mais eficientes em parâmetros.

3.3 Inteligência de borda (*Edge O-RAN e Multi Agent System*)

Os trabalhos desta seção investigam a transição do gerenciamento tradicional de rádio para um ecossistema autônomo e agêntico. A literatura analisada propõe arquiteturas em que LLM atuam como orquestradores em um ciclo contínuo de planejamento, ação, observação e reflexão. Adicionalmente, os estudos exploram o conceito de inteligência ubíqua por meio de uma borda hierárquica, na qual múltiplos agentes LLM, assumindo papéis funcionais distintos, colaboram entre dispositivos móveis e servidores de borda para resolver tarefas complexas.

He et al. (2026) propõem o *Agentic AI-RAN*, uma perspectiva arquitetural em que as entidades da O-RAN são concebidas como agentes orientados a objetivos, capazes de raciocinar e agir de forma autônoma na rede. Os autores definem quatro primitivas agênticas fundamentais: *Plan-Act-Observe-Reflect*, que estrutura o ciclo de tomada de decisão; *Skills-as-tool-use*, que encapsula as interfaces A1, E2 e E2SM como ferramentas invocáveis pelo agente; *Memory and Evidence*, que mantém contexto em múltiplas escalas temporais; e *Self-Management*, que implementa mecanismos de *gating* com *rollback* para garantir a segurança operacional. Um LLM residente no *Non-RT RIC* opera a intervalos de 1 minuto, coordenando decisões de *network slicing*. Avaliações em simulação com 6 Open RAN Radio Units (O-RUs), 12 células e 20 UEs demonstram redução média de 8,83% no uso de recursos, com melhoria de 5,7 a 8,3% na admissão de *slices*, redução de 7,1 a 10,3% no uso de recursos e diminuição de 14,3 a 17,9% na latência no percentil 99 (p99¹). Os autores reconhecem como limitações o *overhead* de controle introduzido pelo agente, a necessidade de gêmeos digitais mais realistas para validação e

¹O percentil N de latência (pN) indica o valor abaixo do qual $N\%$ das medições se encontram. Assim, p99 = 17,9% significa que 99% das requisições foram atendidas com latência inferior a esse limiar.

a ausência de padronização de catálogos de *skills* na O-RAN.

Pellejero et al. (2025) descrevem uma trajetória evolutiva para o gerenciamento autônomo da RAN, estruturada em três níveis de maturidade: *workflows* determinísticos, *AI agents* com capacidade de raciocínio, e *agentic AI* com colaboração multiagente. Os autores identificam quatro padrões de *design* agêntico, reflexão, planejamento, uso de ferramentas e coordenação multiagente, e propõem uma arquitetura com cinco agentes especializados: *Master Orchestrator*, *Analysis*, *Historical Retrieval*, *Documentation* e *Validation*. O caso de uso central consiste no monitoramento autônomo de KPIs 5G por meio de análise de séries temporais, no qual o agente orquestrador delega subtarefas a agentes especializados conforme o contexto da rede. Apenas o nível de *workflow* foi efetivamente implementado, enquanto os níveis de *AI Agent* e *Agentic AI* permanecem ilustrativos. Os autores reconhecem como limitações a escassez de implantações reais de *Large Action Models* (LAMs) em ambientes de telecomunicações, o elevado custo computacional e energético associado, a inadequação dos protocolos de comunicação vigentes para tarefas de alta frequência, e a necessidade de mecanismos de memória de longo prazo e *Retrieval-Augmented Generation* (RAG) para operação robusta.

Yu et al. (2026) propõem o *CORE* (*Collaborative Orchestration Role at Edge*), um *framework* de orquestração distribuída de agentes LLM em infraestruturas de borda hierárquicas para redes 6G. A arquitetura é organizada em três camadas, Infraestrutura 6G, Serviço Principal e Retroalimentação/Otimização, e adota o MCP como protocolo de coordenação inter-agente, com *Directed Acyclic Graphs* (DAGs) para modelagem de dependências entre tarefas. O algoritmo *DynaRole-HEFT* implementa escalonamento com afinidade de papéis (*Role Affinity Scheduling*), permitindo a execução em *pipeline*. Um modelo DeepSeek-R1-distill-LLaMA-70B atua como orquestrador em servidores com 8xNVIDIA A40, enquanto o MiniCPM-v2.6 (8B) é implantado nas bordas com NVIDIA RTX 3090/4090. Os experimentos mostram que o CORE supera a linha de base *Single_Dual_Loop* em 25% nas tarefas de dificuldade média e em 20% nas difíceis, e que o *DynaRole-HEFT* reduz a latência em 52% em relação ao HEFT tradicional. Os autores reconhecem como limitações o tempo de inferência do orquestrador, que varia entre 180 e 320 ms e representa 25 a 40% do atraso fim-a-fim sob alta carga, e os desafios de generalização para ambientes com *hardware* heterogêneo.

Kholmatov et al. (2026) propõem o paradigma *AI-on-RAN*, em que a inferência de IA é executada diretamente no nó de acesso rádio, integrando um motor de processamento à camada *Packet Data Convergence Protocol* (PDCP) do CU-UP da O-RAN. O *framework* é composto por quatro componentes: *Packet Router*, que intercepta *Protocol Data Units* (PDUs) no plano de usuário; *Resource Allocator*, que aplica um *threshold* de 90% de utilização de *Central Processing Unit* (CPU)/*Graphics Processing Unit* (GPU) para escalonamento dinâmico; *Model Hub*, que gerencia o registro de modelos via Docker/Kubernetes; e *Response Gateway*, que entrega a resposta de inferência diretamente ao UE. O sistema expõe *RAN Apps* compatíveis com a O-RAN com acesso ao plano de usuário. A prova de conceito foi conduzida com OpenAirInterface, rádios USRP B210, quatro dispositivos *Commercial Off-The-Shelf* (COTS) Google Pixel

6 e uma CPU NVIDIA RTX 4080. Para um *chatbot* baseado em LLM, a latência p90 foi reduzida em 48% em relação ao MEC convencional e em 85% em relação à nuvem; para detecção de objetos, as reduções foram de 37% e 74%, respectivamente. A execução colaborativa de RAN + MEC mantém a latência p99 fim-a-fim abaixo de 100 ms com 12 UEs simultâneos. Os autores reconhecem como limitações a política de *threshold* estático para alocação de recursos, a necessidade de esquemas *AI-and-RAN* mais sofisticados e a ausência de mecanismos de escalonamento colaborativo dinâmico como trabalho futuro.

3.4 Diagnóstico de falhas e *Self-Organizing Networks*

Os trabalhos reunidos nesta seção visam dotar a rede de capacidades avançadas e autônomas de autocura (*self-healing*) e de auto-otimização. A literatura atual explora *frameworks* em que múltiplos agentes assumem papéis táticos e operacionais distintos, como a análise de tráfego, a garantia de QoS e a detecção de ameaças de segurança, resolvendo, dessa forma, anomalias dinamicamente por meio da colaboração e da validação entre pares.

Shi et al. (2025) propõem um MAS com *Human-in-the-Loop* que combina LLMs para orquestração com *Small Language Models* (SLMs) ajustados por *fine-tuning* para planejamento de soluções em domínios específicos de telecomunicações. O sistema é construído sobre o *framework* HypHa e estende o FastAPI com chamadas de procedimentos remotos via Web-Sockets, integrando seis agentes especializados: *Orchestrator*, *Solution Planner*, *Root Cause Analysis*, *Executor*, *Data Retriever* e *Dashboard Display*. O agente *Solution Planner* utiliza o HippoRAG como *backbone* de recuperação em um grafo de conhecimento construído a partir de documentos proprietários de *troubleshooting*. O *fine-tuning* do SLM adota uma estratégia em dois estágios: *Supervised Fine-Tuning* (SFT) para aquecimento com pares de *Question Answering* (QA) rotulados, seguido de *Reinforcement Fine-Tuning* (RFT) com LoRA e *Group Relative Policy Optimization* (GRPO) para fortalecer o raciocínio, sem necessidade de rotulação extensiva. O modelo base DeepSeek-R1-Qwen-3-8B foi treinado em sete CPUs NVIDIA RTX A6000 com ZeRO Stage-2. Os experimentos demonstram redução de seis vezes no tempo médio de *troubleshooting* por nó e melhoria de 10% na acurácia em relação a processos conduzidos por humanos; o modelo ajustado elevou a recompensa total de 5,96 para 10,51, com redução do desvio padrão de 2,17 para 0,38. Os autores reconhecem como limitações o elevado custo computacional e de capital para a implantação em ambientes de operadoras, os riscos à privacidade de dados ao utilizar provedores externos de LLM e o alto consumo de memória durante o treinamento com janelas de contexto longas.

Qayyum et al. (2025) propõem o *LaMA-SON* (*Large language model-based Multi-Agent System for Self-Organizing Networks*), um *framework* baseado em LLMs para o gerenciamento inteligente de *Self-Organizing Networks* (SONs), com tomada de decisão descentralizada em tempo real nas estações base. A arquitetura organiza agentes em dois níveis: agentes de orquestração central, *Complexity Checker* (*Complexity Checker Agent* (CCA)), *Coordinator* (Co-

ordinator Agent (CA)) e *Recruiter* (*Recruiter Agent* (RA)), e agentes especializados por domínio, *Traffic Analysis* (*Traffic Analysis Agent* (TAA)), *Quality Assurance* (*Quality Assurance Agent* (QAA)), *Threat Detection* (*Threat Detection Agent* (TDA)) e *Decision Maker* (*Decision Maker Agent* (DMA)). O CCA classifica cada requisição em três níveis de complexidade para recrutar dinamicamente o conjunto adequado de agentes, enquanto a memória em nuvem compartilhada viabiliza a comunicação interestações. A implementação utiliza o *framework* Camel-AI com inferência local via Ollama, e os agentes são avaliados no conjunto de dados CIC-BCCC-NRC-IoMT-2024, que contém 200 registros de tráfego. A coordenação multiagente opera em três rodadas de revisão entre pares, permitindo *loops* de retroalimentação corretiva. O *LaMA-SON* obteve acurácia de 0,69, precisão de 0,76 e *recall* de 0,69, mantendo desempenho estável, enquanto modelos isolados, como llama3 e cogito:14b, degradaram significativamente ao escalar de 20 para 200 amostras. Os autores reconhecem como limitações os desafios de escalabilidade do MAS em redes de grande porte, questões de segurança e privacidade na memória compartilhada, a ausência de *benchmarks* padronizados para avaliação de LLMs em contexto de SONs, e a avaliação restrita a um ambiente simulado de *host* único sem cobertura das funcionalidades completas de auto-configuração, auto-otimização e auto-recuperação.

3.5 Protocolos semânticos, revisões sistemáticas e *Surveys*

A literatura analisada nesta seção examina criticamente como os LLMs e os métodos de aprendizado de protocolos baseados em IA estão sendo integrados às arquiteturas O-RAN e 6G. Além de detalharem a formulação matemática de problemas complexos de otimização de rede e o uso de técnicas como RAG, esses estudos servem como guias fundamentais. Eles identificam as principais barreiras que ainda limitam a implantação prática dessas inovações, como a alta complexidade computacional imposta na borda da rede, a ausência de KPI semânticas padronizadas e as novas vulnerabilidades de segurança, estabelecendo um roteiro claro de pesquisa para o futuro das telecomunicações cognitivas.

Tahenni et al. (2026) apresentam um levantamento abrangente sobre protocolos semânticos, aprendizado de protocolos e protocolos semânticos habilitados por IA no contexto das arquiteturas O-RAN e 6G. Os autores propõem uma arquitetura de cinco camadas que integra esses três pilares em um único *framework*: a camada de Serviço, que hospeda casos de uso avançados como comunicações holográficas e gêmeos digitais; a camada de *Service Management and Orchestration* (SMO), com o *Non-RT RIC* e um *Semantic Protocol Designer* centralizado; a camada de Controle Inteligente, com o *Near-RT RIC* e agentes de aprendizado de protocolo executando *xApps* semânticas; a camada de Funções de Rede, com elementos de RAN sensíveis ao contexto; e a camada de Infraestrutura, com unidades de processamento de IA e nós de computação de borda. A metodologia fundamenta-se na entropia semântica, em *Graph Neural Networks* (GNNs) para otimização de *beamforming* com acurácia de 92%, no algoritmo *Soft Actor-Critic* (SAC) para otimização de políticas contínuas e no aprendizado federado para trei-

namento distribuído. Os resultados reportados indicam economia de largura de banda entre 35 e 70% nos estudos revisados, redução de 63% nos erros de configuração por meio de GNNs, melhoria de 28% na taxa de sucesso de *handover* por aprendizado federado e detecção de ataques adversariais com 99,4% de acurácia. Os autores reconhecem como limitações a ausência de *frameworks* padronizados para a troca de informações semânticas nas interfaces E2, A1 e O1 da O-RAN, a complexidade computacional quadrática $O(n^2)$ dos mecanismos de atenção, a carência de KPIs semânticas padronizadas em ambientes multi-fornecedor, e o fato de que apenas 12% dos estudos revisados apresentam validação em ambientes reais, além de simulação.

Wei et al. (2025) apresentam um levantamento e um tutorial sobre *frameworks* de otimização habilitados por LLMs para o gerenciamento de redes sem fio de próxima geração. Os autores estruturam um *pipeline* em três estágios: formulação habilitada por LLM, que traduz descrições em linguagem natural em modelos *Mixed-Integer Linear Programming* (MILP) compatíveis com *solvers*; geração de soluções, que abrange integração com *solvers* clássicos, aumentação heurística, refinamento iterativo e colaboração multiagente; e verificação, que combina checagem sintática, *self-verification* baseada em *prompts* e votação por *ensemble*. Entre os *frameworks* detalhados, destacam-se o OptiMUS, com taxa de sucesso superior a 90% na geração de modelos MILP; o OPTIMA, que obtém desempenho $2,8\times$ superior com menos de 10% de uso de *tokens* em cenários multiagente; e o LLaMEA-HPO, que alcança 20% de melhoria na qualidade das soluções por meio do ajuste automático de hiperparâmetros. Os casos de uso incluem alocação de recursos em redes de satélites *Low Earth Orbit* (LEO) com *Rate-Splitting Multiple Access* (RSMA), roteamento de Veículo Aéreo Não Tripulados (VANTs) com redução de 24,7% na *Age of Information* em relação ao algoritmo guloso, e otimização de taxa em redes LEO com ganho de 11,45% em relação ao *Proximal Policy Optimization* (PPO), com convergência em 30 iterações. Os autores reconhecem como limitações a lacuna semântico-física entre o raciocínio textual dos LLMs e as restrições físicas do canal sem fio, os desafios de latência sub-milissegundo incompatíveis com os tempos de inferência dos modelos, a degradação de desempenho na transferência entre domínios e a ausência de mecanismos robustos de aprendizado contínuo para cenários dinâmicos.

3.6 Discussão e lacunas identificadas

A análise comparativa dos trabalhos relacionados, sintetizada na Tabela 2, revela um panorama marcado por avanços expressivos em dimensões isoladas, porém com lacunas significativas quando se considera a integração simultânea de todos os requisitos necessários a uma solução de orquestração autônoma de redes 5G. Das 17 publicações examinadas, 14 (82%) fazem uso de LLM como componente central de suas arquiteturas, o que evidencia a consolidação desses modelos como ferramenta de suporte à tomada de decisão em redes móveis. Contudo, a abrangência decresce progressivamente nas demais dimensões: oito trabalhos (47%) adotam arquiteturas baseadas em MAS, seis (35%) incorporam princípios de IBN, cinco (29%) vali-

dam suas propostas em *testbeds* reais e apenas cinco (29%) apresentam integração efetiva com o 5GC ou com a NWDAF. Nenhum dos trabalhos examinados reúne simultaneamente todas essas cinco características, o que configura a lacuna central que esta pesquisa se propõe a endereçar.

Uma segunda dimensão de análise refere-se ao domínio de atuação de cada proposta. A coluna “Domínio Principal” da Tabela 2 evidencia que a maioria dos trabalhos foca em um único domínio de infraestrutura: nove trabalhos operam exclusivamente no domínio RAN ou de borda, cinco concentram-se no núcleo da rede (*Core/5GC*), e apenas dois abordam explicitamente a integração entre núcleo e acesso rádio (*Core+RAN*). O presente trabalho distingue-se por cobrir ambos os domínios de forma hierárquica e integrada, por meio de agentes especializados que operam no CN-NSSMF, responsável pelo gerenciamento das funções de núcleo, e no RAN-NSSMF, responsável pela configuração dos recursos de acesso rádio.

No eixo temático dedicado a IBN e NWDAF, os trabalhos investigados exploram aspectos complementares, porém isolados. As contribuições voltadas à tradução de intenções em políticas de rede e ao emprego de LLMs como componente analítico no núcleo da rede demonstram viabilidade técnica dessas abordagens. No entanto, nenhuma delas valida a integração simultânea com infraestrutura 5GC real e com mecanismos formais de orquestração orientada a *slice*. Os trabalhos que adotam o paradigma de IBN fazem-no majoritariamente em ambientes simulados ou em planos de controle abstratos, sem aderência às interfaces normativas definidas pelo 3GPP para o NSSMF. Essa dissociação entre a camada semântica da intenção e a camada operacional da rede constitui uma limitação estrutural recorrente nesse eixo.

Os trabalhos reunidos no eixo de orquestração e *network slicing* avançam na automação do ciclo de vida de fatias de rede, incorporando, em alguns casos, agentes autônomos e modelos de linguagem para geração dinâmica de políticas. Não obstante, a maioria das propostas trata a orquestração de forma plana, sem distinguir a gestão do núcleo da rede (5GC) da gestão do acesso via RAN. A ausência de uma arquitetura hierárquica que decomponha as responsabilidades entre um NSSMF voltado ao núcleo (CN-NSSMF) e um NSSMF dedicado à RAN (RAN-NSSMF) impede que tais sistemas respondam de forma coordenada a requisitos heterogêneos que envolvam simultaneamente parâmetros de transporte, de núcleo e de acesso rádio. Ademais, a ausência de validação em um *testbed* real limita a avaliação da latência de decisão e do comportamento emergente em condições de tráfego não estacionário.

No eixo de MAS aplicado a ambientes de computação de borda e O-RAN, as contribuições examinadas demonstram a capacidade de agentes distribuídos de otimizar recursos em domínios localizados, como células individuais ou segmentos de *fronthaul*. A limitação preponderante nesse grupo reside na ausência de integração com LLMs para interpretação de intenções de alto nível, bem como na falta de conexão com planos de orquestração de *slices* reconhecidos pelo 5GC. Os trabalhos classificados no eixo de diagnóstico e SON focam na automação de tarefas pontuais de manutenção e otimização, sem contemplar a gestão *end-to-end* de *slices* nem a interface com entidades de gerenciamento normativas. As publicações de caráter *survey*,

por sua vez, reforçam, em suas conclusões, a necessidade de sistemas que integrem LLM, automação semântica e orquestração nativa ao 5GC, sem, contudo, apresentarem contribuições arquiteturais originais.

Diante do exposto, constata-se que nenhum dos trabalhos relacionados reúne, de forma integrada e validada experimentalmente, os cinco requisitos identificados como essenciais: (i) emprego de LLM, (ii) arquitetura MAS, (iii) paradigma IBN, (iv) validação em *testbed* real e (v) integração com 5GC/NWDAF. A presente proposta preenche essa lacuna ao conceber uma arquitetura hierárquica em que um agente orquestrador de topo interpreta intenções expressas em linguagem natural por meio de LLM e as decompõe em diretivas operacionais transmitidas a agentes especializados: o CN-NSSMF, responsável pela gestão das funções de núcleo, e o RAN-NSSMF, responsável pela configuração dos recursos de acesso rádio. Essa decomposição hierárquica, implementada e avaliada em um *testbed* real, com integração nativa ao 5GC e à NWDAF, distingue este trabalho de todas as contribuições anteriores e representa um avanço concreto em direção à autonomia cognitiva das redes móveis de quinta geração.

Trabalho	Uso de LLM	Arquitetura MAS	Intent-Based Networking	Testbed Real	Integrado ao 5GC/NWDAF	Eixo Temático
A01	○	○	○	○	○	IV
A02	○	●	○	○	○	III
A03	●	●	○	○	○	III
A04	●	●	●	○	●	I
A05	●	○	●	●	●	II
A06	●	●	○	●	○	III
A07	●	○	●	○	○	II
A08	●	○	●	●	●	I
A09	●	○	○	○	○	IV
A10	●	●	○	○	○	II
A11	●	●	○	○	○	V
A12	●	●	○	○	○	V
A13	●	○	○	○	○	I
A14	●	●	●	○	○	II
A15	○	○	○	●	○	III
A16	●	○	●	○	●	I
A17	●	●	○	●	●	II
Este trabalho	●	●	●	●	●	I–V

(●) Presença da característica; (○) ausência. Eixos temáticos: (I) IBN e NWDAF; (II) Orquestração e *Network Slicing*; (III) Borda e O-RAN; (IV) *Surveys*; (V) Diagnóstico e SON.

Tabela 2: Características dos trabalhos relacionados.

4 MINAS - MULTI-AGENT INTENT-DRIVEN NETWORK ANALYTICS AND SLICING

Este capítulo apresenta o MINAS, uma arquitetura de orquestração autônoma de fatias de rede 5G baseada em MAS e LLMs. A solução é organizada em três camadas funcionais: a camada de intenção, responsável pela captura dos objetivos do operador em linguagem natural; a camada de orquestração agêntica, composta por um agente orquestrador e dois agentes especializados de domínio; e a camada de infraestrutura de rede, que concentra as funções de núcleo e de acesso rádio. Toda a coordenação entre os agentes de domínio é mediada pelo orquestrador por meio de um protocolo de invocação de ferramentas. Dois casos de uso orientam a avaliação experimental: o ajuste reativo e preditivo de recursos de fatia e a coordenação de política de QoS com janela temporal entre núcleo e acesso rádio.

4.1 Arquitetura do sistema proposto

A arquitetura do MINAS é organizada em três camadas funcionais, ilustradas na Figura 6.

Camada de intenção

A camada de intenção é o ponto de entrada do sistema. O operador expressa os objetivos de negócio em linguagem natural, por exemplo, “*garantir latência inferior a 10 ms para a fatia de missão crítica durante o turno da tarde*”, sem necessidade de conhecer as interfaces normativas do 5GC ou os parâmetros internos de configuração da RAN. A intenção é transmitida diretamente ao agente orquestrador, que a processa e a traduz em diretivas operacionais.

Camada de orquestração agêntica

A camada de orquestração agêntica é composta por três agentes LLM. O agente orquestrador é o único ponto de coordenação do sistema: recebe a intenção do operador, a interpreta via LLM, decompõe-a em diretivas operacionais e as transmite aos dois agentes de domínio por meio de um protocolo de invocação de ferramentas. Os agentes de domínio não se comunicam diretamente entre si; toda coordenação, incluindo operações de sincronização como a reversão de políticas ao término de uma janela temporal, é mediada pelo orquestrador.

O **CN-NSSMF** é o agente especializado nas funções de núcleo da rede. Ele configura e monitora os recursos associados a cada fatia nas funções de controle de sessão, política e mobilidade do 5GC, e obtém telemetria e predições analíticas a partir da NWDAF por meio das interfaces normativas de subscrição de eventos e recuperação de análises (3GPP, 2023c), seguindo a abordagem adotada em (AMEUR; BRIK; KSENTINI, 2026). O agente reporta o estado de cumprimento de SLA ao orquestrador de forma contínua.

O **RAN-NSSMF** é o agente especializado nos recursos de acesso rádio. Ele traduz as dire-

tivas recebidas em parâmetros de configuração dos nós de acesso, ajusta a alocação de recursos por fatia e reporta métricas do plano de usuário ao orquestrador.

Camada de infraestrutura de rede

A camada de infraestrutura compreende as funções de núcleo 5G, AMF, SMF, PCF, UPF e NWDAF, e os elementos de acesso rádio, que simulam nós *Next Generation Node B* (gNodeB) e equipamentos de usuário com suporte a múltiplas fatias simultâneas via S-NSSAI. O ambiente é executado em nuvem, sem dependência de hardware de rádio físico. Os três fluxos principais do sistema são:

- **Fluxo de intenção:** o operador submete uma intenção ao agente orquestrador, que a processa via LLM e emite diretivas ao CN-NSSMF e ao RAN-NSSMF por meio do protocolo de invocação de ferramentas;
- **Fluxo de telemetria:** o CN-NSSMF obtém métricas e análises preditivas da NWDAF via interfaces normativas; o RAN-NSSMF coleta métricas dos elementos de acesso rádio; ambos reportam o estado de SLA ao orquestrador, que mantém a visão consolidada do sistema;
- **Fluxo de execução:** os agentes de domínio invocam as interfaces normativas do 5GC e dos elementos de acesso rádio para efetivar as reconfigurações determinadas pelo orquestrador.

4.2 Decisões de projeto

Nesta seção são justificadas as escolhas conceituais que fundamentam a arquitetura proposta.

Ambiente de implementação em nuvem

O ambiente experimental será construído sobre componentes de código aberto executados em contêineres, sem dependência de hardware de rádio físico. Essa decisão garante a reprodutibilidade dos experimentos, o isolamento de falhas e a facilidade de escalonamento. A emulação da rede de acesso rádio não implementa o fatiamento na RAN com o mesmo nível de fidelidade de uma pilha de rádio aberta com unidades CU/DU reais e suporte a RIC; sua adoção é justificada pela maturidade da integração com o núcleo e pela adequação ao escopo deste trabalho, cujo foco está na camada de orquestração agêntica. A substituição por uma pilha O-RAN com suporte a RIC constitui uma extensão natural para trabalhos futuros.




Figura 6: Arquitetura em camadas do MINAS.

Coordenação centralizada no orquestrador

A decisão de mediar toda a comunicação entre agentes pelo orquestrador, sem canal direto entre CN-NSSMF e RAN-NSSMF, justifica-se por três razões. Primeiro, é consistente com o modelo BDI hierárquico descrito no Capítulo 2, no qual o orquestrador mantém as crenças consolidadas do sistema e é o único agente com autoridade para emitir novos planos de ação. Segundo, simplifica a implementação e a depuração do sistema, eliminando estados inconsistentes que poderiam surgir de decisões tomadas bilateralmente pelos agentes de domínio. Terceiro, é o modelo adotado pela maioria dos trabalhos relacionados à arquitetura hierárquica de agentes em redes 5G (AMEUR; BRIK; KSENTINI, 2026; GEMAYEL; MOKH, 2025; BANDARA et al., 2025).

Protocolo de coordenação via invocação de ferramentas

O MCP foi adotado como mecanismo de comunicação entre os agentes e as interfaces de rede por permitir a invocação dinâmica de APIs sem retreinamento dos modelos, o que é essencial em ambientes em que as interfaces normativas do 3GPP evoluem com frequência. Sua eficácia no contexto de orquestração 5G foi demonstrada em trabalhos recentes, com taxas de

acurácia na seleção de ferramentas entre 85% e 95% (AMEUR; BRIK; KSENTINI, 2026; SOLIMAN et al., 2026).

Algoritmo de predição

O algoritmo *Random Forest* foi escolhido para o Caso de Uso 1 por três razões. Primeiro, apresenta desempenho consolidado em tarefas de predição de séries temporais de telemetria de rede em cenários equivalentes ao deste trabalho (SOLIMAN et al., 2026). Segundo, opera com baixa latência de inferência, sem necessidade de unidade de processamento gráfico, compatível com o ambiente experimental em nuvem adotado. Terceiro, oferece interpretabilidade nativa por meio da importância atribuída às características, facilitando a auditoria das predições em contextos de missão crítica (GARCIA et al., 2023). Como parte da avaliação experimental, será realizada uma comparação com *Gradient Boosting* e redes *Long Short-Term Memory* (LSTM), a fim de validar a escolha a posteriori.

Seleção do modelo LLM

O modelo LLM será selecionado com base no desempenho em *tool-calling* e no raciocínio sobre o contexto normativo do 3GPP, avaliados em um *benchmark* de intenções derivado da especificação TS 28.312. A prioridade recai sobre modelos com suporte confiável a chamadas de ferramentas, dado que a acurácia de seleção de APIs é uma das métricas centrais de avaliação do sistema (AMEUR; BRIK; KSENTINI, 2026; SOLIMAN et al., 2026). Os modelos serão executados localmente por meio de um servidor de inferência, preservando a privacidade dos dados de telemetria e eliminando dependência de serviços externos.

Estrutura interna dos agentes

Os três agentes seguem o paradigma *ReAct* (*Reasoning and Acting*) (YAO et al., 2023), no qual o LLM alterna entre ciclos de raciocínio sobre o estado atual da rede, seleção de uma ferramenta, observação do resultado e decisão da próxima ação. Nenhum dos agentes passa por *fine-tuning*: o domínio de telecomunicações é injetado em tempo de execução por meio de um *system prompt* que define o papel do agente, suas restrições operacionais e o vocabulário normativo do 3GPP relevante ao seu domínio, complementado por RAG sobre as especificações TS 28.312 e TS 23.288 para mitigar alucinações (LEWIS et al., 2020; AMEUR; BRIK; KSENTINI, 2026). Cada agente é caracterizado por um conjunto de ferramentas que expõe as interfaces que ele pode invocar. O agente orquestrador possui ferramentas para decomposição de intenções e monitoramento agregado de SLA, mas não acessa diretamente as interfaces do núcleo ou da RAN, sua função é puramente semântica. O CN-NSSMF expõe ferramentas para consulta à NWDAF, configuração de QoS nas funções de sessão e atualização de políticas nas

funções de controle de política. O RAN-NSSMF expõe ferramentas para coleta de métricas dos elementos de acesso rádio e ajuste dos parâmetros de alocação de recursos por fatia. Essa separação garante que cada agente de domínio opere apenas sobre os elementos de rede sob sua jurisdição.

O mapeamento para o modelo BDI é direto: as crenças de cada agente correspondem ao estado da rede obtido via telemetria (NWDAF para o CN-NSSMF, elementos de acesso rádio para o RAN-NSSMF); os desejos correspondem aos parâmetros de SLA extraídos da diretiva recebida do orquestrador; e as intenções são os planos de reconfiguração gerados pelo LLM e executados por meio das interfaces normativas.

4.3 Casos de uso e avaliação de desempenho

Para a realização dos testes de desempenho, serão utilizados dois casos de uso práticos que orientam a avaliação experimental no ambiente de prototipagem.

Caso de uso 1 — Predição e ajuste de recursos de fatia

O primeiro caso de uso avalia a capacidade do sistema de antecipar o esgotamento dos recursos em uma fatia ativa. Diante de uma intenção como “*garantir disponibilidade de memória acima de 80% para a fatia de vídeo durante o período de pico*”, o CN-NSSMF consulta periodicamente a NWDAF, que aplica um modelo preditivo treinado a partir de séries históricas de telemetria para prever a utilização de memória com um horizonte de 60 segundos. Quando a previsão ultrapassa o limiar configurado, o CN-NSSMF reporta ao orquestrador, que decide e aciona automaticamente a ampliação dos recursos da fatia por meio das interfaces normativas do 5GC. Quando os recursos disponíveis são insuficientes para atender à ampliação solicitada, o orquestrador adota uma estratégia de degradação graciosa: notifica o operador sobre a indisponibilidade, registra o evento de violação de SLA e, se configurado, redistribui os recursos entre as fatias ativas de acordo com as prioridades definidas na política de operação. Esse cenário de esgotamento é parte integrante da avaliação experimental e permite verificar o comportamento do sistema sob condições de contenda por recursos. O fluxo de execução está ilustrado na Figura 7.

Caso de uso 2 — Política de QoS agendada com coordenação núcleo–RAN

O segundo caso de uso avalia a coordenação entre os dois agentes de domínio mediada pelo orquestrador. A intenção “*aumentar a taxa de dados garantida para a fatia de streaming de 10 Mbps para 20 Mbps entre 18h e 22h*” é decomposta pelo agente orquestrador em duas diretivas paralelas: o CN-NSSMF reconfigura os parâmetros de QoS nas funções de política e de controle de sessão; o RAN-NSSMF ajusta a alocação de recursos nos nós de acesso rádio.




Figura 7: Diagrama de sequência do Caso de Uso 1 — previsão e ajuste autônomo de recursos de fatia.

Durante a janela ativa, ambos os agentes reportam continuamente o estado de SLA ao orquestrador. No término do intervalo, o orquestrador envia diretivas de reversão a cada agente de domínio, que restauram as configurações ao estado anterior. O fluxo completo está ilustrado na Figura 8.

Para a avaliação, serão aferidos os seguintes indicadores:

- **Latência de decisão:** intervalo entre a recepção da intenção e a efetivação da configuração nos elementos de rede;
- **Taxa de cumprimento de SLA:** fração do tempo em que os parâmetros de QoS observados atendem aos objetivos declarados, incluindo os cenários de esgotamento de recursos;
- **Acurácia de seleção de ferramentas:** proporção de chamadas de interface corretamente identificadas e executadas pelo LLM (AMEUR; BRIK; KSENTINI, 2026);
- **Taxa de sucesso de tarefas:** fração das intenções processadas que resultam em uma configuração bem-sucedida, verificada no ambiente experimental.




Figura 8: Diagrama de sequência do Caso de Uso 2 — política de QoS agendada com coordenação núcleo-RAN.

5 CONSIDERAÇÕES FINAIS

Neste trabalho, foram apresentados os fundamentos teóricos e o estado da arte necessários ao desenvolvimento do MINAS, um sistema de orquestração autônoma de fatias de rede 5G baseado em MAS e LLMs. Foi discutida a evolução arquitetural do núcleo da rede, desde o EPC do 4G até a SBA do 5GC, com ênfase no papel da NWDAF como elemento central de inteligência analítica. Foram ainda apresentados os fundamentos do MCP como protocolo de coordenação entre agentes e do paradigma *ReAct* como mecanismo de raciocínio e ação dos LLMs. Identificou-se o paradigma de IBN como uma abordagem essencial para substituir configurações manuais por diretrizes expressas em linguagem natural, e os LLMs como tradutores semânticos capazes de interpretar essas intenções e convertê-las em ações executáveis sobre a infraestrutura de rede.

Foi realizada uma revisão sistemática de dezessete trabalhos relacionados, organizados em cinco eixos temáticos: IBN e NWDAF, orquestração e *network slicing*, inteligência de borda e O-RAN, diagnóstico autônomo de falhas e *surveys*. A análise comparativa revelou que, embora os trabalhos recentes apresentem avanços expressivos em dimensões isoladas, nenhum deles reúne simultaneamente os cinco requisitos identificados como essenciais: emprego de LLM, arquitetura MAS, paradigma IBN, validação em *testbed* real e integração com 5GC e NWDAF.

Por fim, foi proposto o MINAS, uma arquitetura hierárquica composta por um agente orquestrador e dois agentes especializados, CN-NSSMF e RAN-NSSMF, implantados como contêineres Docker e integrados à NWDAF por meio de suas interfaces normativas. Toda a coordenação é mediada pelo agente orquestrador por meio da MCP, seguindo o modelo BDI hierárquico. Os agentes operam sem *fine-tuning*, com o domínio de telecomunicações injetado em tempo de execução por meio de um *system prompt* e de RAG sobre as especificações do 3GPP. O sistema será validado em um ambiente experimental em nuvem com Open5GS e UE-RANSIM, por meio de dois casos de uso: predição e ajuste autônomo de recursos de fatia e política de QoS agendada com coordenação núcleo–RAN.

As próximas etapas para o prosseguimento do trabalho estão descritas na Tabela 3. Acredita-se que o MINAS consolidará o valor dos LLMs e dos MAS para a automação cognitiva das redes móveis de quinta geração, contribuindo para a construção de infraestruturas mais autônomas, resilientes e orientadas a intenções.

Tabela 3: Cronograma das próximas etapas do trabalho.

Etapa	Agosto	Setembro	Outubro	Novembro	Dezembro
Configurar o <i>testbed</i> (Open5GS + UERANSIM)	●	○	○	○	○
Implementar o agente orquestrador com LLM local	○	●	○	○	○
Implementar o CN-NSSMF e integrar à NWDAF	○	●	●	○	○
Implementar o RAN-NSSMF e integrar ao UERANSIM	○	●	●	○	○
Validar o caso de uso 1 (predição de recursos)	○	○	●	○	○
Validar o caso de uso 2 (política de QoS agendada)	○	○	●	○	○
Avaliar as métricas de desempenho	○	○	○	●	○
Escrita do trabalho	○	○	●	●	●

(●) Etapa em progresso e (○) etapa parada.

REFERÊNCIAS

- 3GPP. **Study on New Radio Access Technology: Radio Access Architecture and Interfaces**. [S.l.], 2017. Release 14. Disponível em: <https://www.3gpp.org/ftp/Specs/archive/38_series/38.801/>.
- 3GPP. **TS 23.288: Architecture enhancements for 5G System (5GS) to support network data analytics services**. [S.l.], 2023. Release 17.
- 3GPP. **TS 28.312: Management and orchestration; Intent driven management services for mobile networks**. [S.l.], 2023. Release 17.
- 3GPP. **TS 29.520: 5G System; Network Data Analytics Services; Stage 3**. [S.l.], 2023. Release 17.
- 3GPP. **5G System; Technical Realization of Service Based Architecture; Stage 3**. [S.l.], 2024. Release 18. Disponível em: <https://www.3gpp.org/ftp/Specs/archive/29_series/29.500/>.
- 3GPP. **Management and orchestration; Architecture framework for management and orchestration of networks and network slicing**. [S.l.], 2024. Release 18. Disponível em: <https://www.3gpp.org/ftp/Specs/archive/28_series/28.533/>.
- 3GPP. **System Architecture for the 5G System (5GS)**. [S.l.], 2024. Release 18. Disponível em: <https://www.3gpp.org/ftp/Specs/archive/23_series/23.501/>.
- AGARWAL, S. et al. Software-defined agentic serving. **arXiv preprint arXiv:2601.03197**, 2026.
- ALLIANCE, O.-R. **O-RAN Architecture Description v07.00**. 2022.
- AMEUR, M.; BRIK, B.; KSENTINI, A. Agentic-nwdaf: Enabling intent-driven agentic intelligence for autonomous 6g network analytics. In: **IEEE ICC 2026**. Glasgow: [s.n.], 2026.
- BANDARA, E. et al. Slice-mcp — fine-tuned llama-4 llm and mcp enabled 5g network slice orchestration platform. In: **IEEE MILCOM 2025**. [S.l.: s.n.], 2025.
- BARIAH, L. et al. Large generative ai models for telecom: The next big thing? **IEEE Communications Magazine**, 2024.
- BARIAH, L. et al. Large Generative AI Models for Telecom: The Next Big Thing? **IEEE Communications Magazine**, v. 62, n. 11, p. 84–90, 2024.
- BNEB. **Trytet: Deterministic WASM substrate for stateful AI agents**. [S.l.], 2026. Disponível em: <<https://trytet.com>>.
- BRATMAN, M. E. **Intention, Plans, and Practical Reason**. Cambridge, MA: Harvard University Press, 1987.
- BRODIMAS, D. et al. Intent-based infrastructure and service orchestration via agentic ai and large language models. **IEEE Open Journal of the Communications Society**, v. 6, 2025.
- DANDOUSH, A. et al. **Large Language Models meet Network Slicing Management and Orchestration**. 2024. Disponível em: <<https://arxiv.org/abs/2403.13721>>.

EHTESHAM, A. et al. A survey of agent interoperability protocols: Mcp, acp, a2a, and anp. **arXiv preprint arXiv:2505.02279**, 2025.

ETSI. **Zero-touch Network and Service Management (ZSM); Reference Architecture**. [S.l.], 2019. Disponível em: <https://www.etsi.org/deliver/etsi_gs/ZSM/001_099/002/>.

ETSI. **Zero-touch Network and Service Management (ZSM); Closed-Loop Automation; Part 1: Enablers**. [S.l.], 2021. Disponível em: <https://www.etsi.org/deliver/etsi_gs/ZSM/001_099/00901/>.

GARCIA, A. et al. Analytical hubs in 5g core: A study on nwdaf and ml. **IEEE Access**, 2023.

GEMAYEL, J.; MOKH, A. Network function orchestration with llm based multi-agent system. In: **IEEE ICC Workshops 2025**. [S.l.: s.n.], 2025. p. 262–267.

HE, Z. et al. **Agentic AI-RAN: Enabling Intent-Driven, Explainable and Self-Evolving Open RAN Intelligence**. 2026. Disponível em: <<https://arxiv.org/abs/2602.24115>>.

JIANG, G. et al. Hierarchical llm-agent for autonomous intent-based orchestration in 6g networks. **arXiv preprint arXiv:2601.06640**, 2025.

KAN, K. B. et al. Mobile-llama: Instruction fine-tuning open-source llm for network analysis in 5g networks. **IEEE Network**, v. 38, n. 5, p. 76–83, 2024.

KEPHART, J. O.; CHESS, D. M. The Vision of Autonomic Computing. **Computer**, IEEE, v. 36, n. 1, p. 41–50, 2003.

KHOLMATOV, S. et al. Toward ai-on-ran: Enabling on-ran edge intelligence for ai-native 6g networks. **IEEE Network**, 2026.

KWON, W. et al. Efficient Memory Management for Large Language Model Serving with PagedAttention. In: **Proceedings of the 29th Symposium on Operating Systems Principles (SOSP)**. [S.l.: s.n.], 2023. p. 611–626.

LEWIS, P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [s.n.], 2020. v. 33, p. 9459–9474. Disponível em: <<https://arxiv.org/abs/2005.11401>>.

MANIAS, D. M. et al. **Towards Intent-Based Network Management: Large Language Models for Intent Extraction in 5G Core Networks**. 2024. Disponível em: <<https://arxiv.org/abs/2403.02238>>.

MAYER, C. et al. Service-based architecture for 5g core networks. **IEEE Communications Standards Magazine**, 2018.

MEKRACHE, A. et al. Dmo-gpt: An intent-driven framework for distributed 6g management and orchestration. **IEEE Communications Magazine**, v. 64, n. 1, 2026.

MOREIRA, R. et al. Agora: Agentic green orchestration architecture for beyond 5g networks. **IEEE Access**, 2026.

O-RAN ALLIANCE. **O-RAN Working Group 2: AI/ML Workflow Description and Requirements**. [S.l.], 2023. Disponível em: <<https://www.o-ran.org/specifications>>.

O-RAN ALLIANCE. **O-RAN Working Group 2 (Non-RT RIC and A1 Interface): Non-RT RIC Architecture**. [S.l.], 2023. Disponível em: <<https://www.o-ran.org/specifications>>.

O-RAN ALLIANCE. **O-RAN Working Group 3 (Near-RT RIC and E2 Interface): Near-RT RIC Architecture**. [S.l.], 2023. Disponível em: <<https://www.o-ran.org/specifications>>.

OLIVEIRA, R. et al. Nwdaf maturity: From release 15 to 18. **Future Generation Computer Systems**, 2024.

PATEL, P. et al. Splitwise: Efficient Generative LLM Inference Using Phase Splitting. In: **Proceedings of the 51st Annual International Symposium on Computer Architecture (ISCA)**. [S.l.: s.n.], 2024. p. 118–132.

PELLEJERO, J. et al. **Agentic AI for Mobile Network RAN Management and Optimization**. 2025. Disponível em: <<https://arxiv.org/abs/2511.02532>>.

POLESE, M. et al. Understanding O-RAN: Architecture, Interfaces, Algorithms, Security, and Research Challenges. **IEEE Communications Surveys & Tutorials**, v. 25, n. 2, p. 1376–1411, 2023.

QAYYUM, A. et al. Llm-driven multi-agent architectures for intelligent self-organizing networks. **IEEE Network**, p. 1–10, 2025.

RAO, A. S.; GEORGEFF, M. P. BDI Agents: From Theory to Practice. In: **Proceedings of the First International Conference on Multi-Agent Systems (ICMAS)**. San Francisco, CA, USA: [s.n.], 1995. p. 312–319.

RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. 3rd. ed. [S.l.]: Pearson, 2010.

SCHICK, T. et al. Toolformer: Language Models Can Teach Themselves to Use Tools. In: **Advances in Neural Information Processing Systems (NeurIPS)**. [s.n.], 2023. v. 36. Disponível em: <<https://arxiv.org/abs/2302.04761>>.

SHI, C. et al. **Leveraging Multi-Agent System (MAS) and Fine-Tuned Small Language Models (SLMs) for Automated Telecom Network Troubleshooting**. 2025. Disponível em: <<https://arxiv.org/abs/2511.00651>>.

SOLIMAN, A. et al. **IntAgent: NWDAF-Based Intent LLM Agent Towards Advanced Next Generation Networks**. 2026. Disponível em: <<https://arxiv.org/abs/2601.13114>>.

SOLO.IO; HAT, R. **llm-d: Kubernetes-native high-performance distributed LLM inference framework**. [S.l.], 2026. Disponível em: <<https://llm-d.ai>>.

TAHENNI, A. et al. A survey on 6g and o-ran intelligence: Semantic protocols, protocol learning, and ai-enabled semantic protocols. **Computer Networks**, v. 279, p. 112143, 2026.

TM Forum. **Autonomous Networks Reference Architecture**. [S.l.], 2022. Disponível em: <<https://www.tmforum.org/resources/standard/ig1230-autonomous-networks-reference-architecture/>>.

VASWANI, A. et al. Attention is all you need. In: **Advances in Neural Information Processing Systems**. [S.l.: s.n.], 2017.

WEI, B. et al. **Large Language Models for Next-Generation Wireless Network Management: A Survey and Tutorial**. 2025. Disponível em: <<https://arxiv.org/abs/2509.05946>>.

WOOLDRIDGE, M. **An Introduction to MultiAgent Systems**. 2nd. ed. Chichester, UK: John Wiley & Sons, 2009.

YAO, S. et al. ReAct: Synergizing Reasoning and Acting in Language Models. In: **Proceedings of the 11th International Conference on Learning Representations (ICLR)**. [s.n.], 2023. Disponível em: <<https://arxiv.org/abs/2210.03629>>.

YU, Z. et al. **CORE: Toward Ubiquitous 6G Intelligence Through Collaborative Orchestration of Large Language Model Agents Over Hierarchical Edge**. 2026. Disponível em: <<https://arxiv.org/abs/2601.21822>>.

ZHOU, H. et al. Large language models for telecom networks: Fundamentals, applications, and future directions. **IEEE Communications Surveys Tutorials**, 2024.

ZOU, H. et al. **TelecomGPT: A Framework to Build Telecom-Specific Large Language Models**. 2024. Disponível em: <<https://arxiv.org/abs/2407.09424>>.

ČAUŠEVIĆ, A.; MEDIĆ, A. 5g technology: Communication innovation and impact on digital transformation. **MIPRO**, 2021.